

Imagenetとは大きく異なる。そのため、DN2ライクな手法が非常に幅広く適用できることを期待している。

外部監視 DN2の成功の鍵となるのは、高品質の外部特徴抽出器を利用できることである。我々が使用したResNet抽出器は、以前Imagenetでトレーニングされたものです。一般的に、監視を使用することは、自己監視の方法よりも高価で手間がかかると考えられています。しかしこの場合、私たちはそれが不利だとは全く考えていません。私たちは、すでに訓練され、無料のオープンソースソフトウェアライブラリのように汎用化されているネットワークを使用した。それらは完全に無料で入手可能であり、新しいデータセットに対してそのようなネットワークを使用するために新たな監視は全く必要なく、トレーニングにかかる時間やストレージのコストも最小限である。全てのプロセスはPyTorchの1行で構成されているため、この場合、これらの手法が教師ありかどうかの議論は純粋に哲学的なものであると我々は考えている。

非常に大きなデータセットへのスケールアップ： ニアレストネイバーは大規模なデータセットに対して遅いことで有名である。この複雑さはニューラルネットワークのようなパラメトリック分類器ではそれほど深刻ではありません。これはニアレストネイバー分類でよく知られた問題であるため、これを回避するために多くの研究が行われた。1つの解決策は、kd-treeなどによる高速なkNN検索である。第5節で使用されるもう1つの解決策は、k-meansを計算し、その上でkNNを計算することによって訓練集合を削減することで、kNNを高速化することを提案した。これは、再帰的K-meansアルゴリズムによってNNを近似する確立された手法によってさらに一般化される (Fukunaga & Narendra, 1975)。実際には、実行時間のほとんどは、最近傍検索ではなく、テスト画像に対するニューラルネットワーク推論の結果になると予想されます。

非画像データ： 非画像データ：我々の調査により、画像異常検知のための非常に強力なベースラインが確立された。しかし、この結果は必ずしも全ての異常検知タスクがこの方法で実行できることを意味しない。一般的な特徴抽出器は画像上で非常に成功しており、他のタスク例えば自然言語処理 (BERT (Devlin et al.)) しかし、表データや時系列データなど、異常検出にとって最も重要な分野ではそうではない。これらの場合、一般的な特徴抽出器は存在せず、データセット間の分散が非常に大きいため、そのような特徴抽出器を作成するための明白な道筋はない。しかし、表データでは一般的にディープメソッドはあまり成功しないため、生データにおけるkNNのベースラインは非常に強力なものであることに留意されたい。それはともかく、我々はこれらのデータモダリティが、自己教師付き異常検知にとって最も有望な分野であると信じている。Bergman & Hoshen (2020)はこれに沿った方法を提案した。

## 7. Conclusion

我々は、単純な方法である深層画像特徴上のkNNを、半教師付き及び教師なし異常検知のための現在のアプローチと比較した。その単純さにもかかわらず、この単純な手法は、精度、学習時間、入力不純物に対する頑健性、データセットのタイプに対する頑健性、サンプルの複雑さの点で、最先端の手法を凌駕することが示された。我々は、より複雑なアプローチが最終的にこの単純なアプローチを凌駕すると信じているが、DN2は、異常検出の実践者にとって優れた出発点であると同時に、将来の研究のための重要なベースラインであると考ええる。

## References

- アーメッド、F. とクールヴィル、A. 意味的異常の検出. arXiv preprint arXiv:1908.04388, 2019.
- Bergman, I. and Hoshen, Y. Classification-based anomaly detection for general data. In *ICLR*, 2020.
- Candès, E. J., Li, X., Ma, Y., and Wright, J. Robust principal component analysis? *JACM*, 2011.
- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- DOro, P., Nasca, E., Masci, J., and Matteucci, M. Group anomaly detection via graph autoencoders. 2019.
- Elson, J., Douceur, J. R., Howell, J., and Saul, J. Asirra: a captcha that exploits interest-aligned manual image categorization. In *ACM Conference on Computer and Communications Security*, volume 7, pp. 366–374, 2007.
- Eskin, E., Arnold, A., Prerau, M., Portnoy, L., and Stolfo, S. A geometric framework for unsupervised anomaly detection. In *Applications of data mining in computer security*, pp. 77–101. Springer, 2002.
- Fukunaga, K. and Narendra, P. M. A branch and bound algorithm for computing k-nearest neighbors. *IEEE transactions on computers*, 100(7):750–753, 1975.
- Gidaris, S., Singh, P., and Komodakis, N. Unsupervised representation learning by predicting image rotations. *ICLR*, 2018.
- Golan, I. and El-Yaniv, R. Deep anomaly detection using geometric transformations. In *NeurIPS*, 2018.
- Gu, X., Akoglu, L., and Rinaldo, A. Statistical analysis of nearest neighbor methods for anomaly detection. In *NeurIPS*, 2019.

are very different from Imagenet. We therefore expect DN2-like methods to be very broadly applicable.

**External supervision:** The key enabler for DN2’s success is the availability of a high quality external feature extractor. The ResNet extractor that we used was previously trained on Imagenet. Using supervision is typically seen as being more expensive and laborious than self-supervised methods. In this case however, we do not see it as a disadvantage at all. We used networks that have already been trained and are as commoditized as free open-source software libraries. They are available completely free, no new supervision at all is required for using such networks for any new dataset, as well as minimal time or storage costs for training. The whole process consists of merely a single PyTorch line, we therefore believe that in this case, the discussion of whether these methods can be considered supervised is purely philosophical.

**Scaling up to very large datasets:** Nearest neighbors are famously slow for large datasets, as the runtime increases linearly with the amount of training data. The complexity is less severe for parametric classifiers such as neural networks. As this is a well known issue with nearest neighbors classification, much work was performed at circumventing it. One solution is fast kNN retrieval e.g. by kd-trees. Another solution used in Sec. 5, proposed to speed up kNN by reducing the training set through computing its k-means and computing kNN on them. This is generalized further by an established technique that approximates NN by a recursive K-means algorithm (Fukunaga & Narendra, 1975). We expect that in practice, most of the runtime will be a result of the neural network inference on the test image, rather than on nearest neighbor retrieval.

**Non-image data:** Our investigation established a very strong baseline for image anomaly detection. This result, however, does not necessarily mean that all anomaly detection tasks can be performed this way. Generic feature extractors are very successful on images, and are emerging in other tasks e.g. natural language processing (BERT (Devlin et al., 2018)). This is however not the case in some of the most important areas for anomaly detection i.e. tabular data and time series. In those cases, general feature extractors do not exist, and due to the very high variance between datasets, there is no obvious path towards creating such feature extractors. Note however that as deep methods are generally less successful on tabular data, the baseline of kNN on raw data is a very strong one. That withstanding, we believe that these data modalities present the most promising area for self-supervised anomaly detection. Bergman & Hoshen (2020) proposed a method along these lines.

## 7. Conclusion

We compare a simple method, kNN on deep image features, to current approaches for semi-supervised and unsupervised anomaly detection. Despite its simplicity, the simple method was shown to outperform the state-of-the-art methods in terms of accuracy, training time, robustness to input impurities, robustness to dataset type and sample complexity. Although, we believe that more complex approaches will eventually outperform this simple approach, we think that DN2 is an excellent starting point for practitioners of anomaly detection as well as an important baseline for future research.

## References

- Ahmed, F. and Courville, A. Detecting semantic anomalies. *arXiv preprint arXiv:1908.04388*, 2019.
- Bergman, I. and Hoshen, Y. Classification-based anomaly detection for general data. In *ICLR*, 2020.
- Candès, E. J., Li, X., Ma, Y., and Wright, J. Robust principal component analysis? *JACM*, 2011.
- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- DOro, P., Nasca, E., Masci, J., and Matteucci, M. Group anomaly detection via graph autoencoders. 2019.
- Elson, J., Douceur, J. R., Howell, J., and Saul, J. Asirra: a captcha that exploits interest-aligned manual image categorization. In *ACM Conference on Computer and Communications Security*, volume 7, pp. 366–374, 2007.
- Eskin, E., Arnold, A., Prerau, M., Portnoy, L., and Stolfo, S. A geometric framework for unsupervised anomaly detection. In *Applications of data mining in computer security*, pp. 77–101. Springer, 2002.
- Fukunaga, K. and Narendra, P. M. A branch and bound algorithm for computing k-nearest neighbors. *IEEE transactions on computers*, 100(7):750–753, 1975.
- Gidaris, S., Singh, P., and Komodakis, N. Unsupervised representation learning by predicting image rotations. *ICLR*, 2018.
- Golan, I. and El-Yaniv, R. Deep anomaly detection using geometric transformations. In *NeurIPS*, 2018.
- Gu, X., Akoglu, L., and Rinaldo, A. Statistical analysis of nearest neighbor methods for anomaly detection. In *NeurIPS*, 2019.