

視覚的異常検出は非常に価値がありますが、同時に非常に困難な課題です。すべての異常検出手法に共通する課題の一つは、異常の予期せぬ性質です。監督学習分類では、テストクラスはトレーニングデータと類似した分布から生成されます。しかし、ほとんどの異常検出設定では、異常の分布はトレーニング時に観測されません。異なる異常検出手法は、訓練時に異常がどのように観測されるかによって異なります。本論文では、訓練時に正常データのみ（異常は観測されない）が観測される設定を扱います。これは実践的に有用な設定であり、正常データ（例えば、欠陥のない製品）を取得することは通常容易だからです。この設定は時々「半教師付き学習」と呼ばれます（[7]）。この表記が曖昧であるため、本論文ではこの設定を「正常データのみ訓練設定」と呼びます。より簡単なシナリオは完全監督型であり、つまり訓練時に正常例と異常例の両方がラベル付きで提示されます。この訓練設定は標準的な監督型分類と類似しており、成熟したタスクで有効な解決策が存在するため、本研究では扱いません。

視覚的異常検出（非画像異常検出手法とは異なる）における特有の課題の一つは、異常の局所化、すなわちアルゴリズムが異常と判断した画像の領域をセグメント化することです。これは、アルゴリズムの意思決定の解説可能性を確保するだけでなく、オペレーターと新たなAIシステム間の信頼関係を築く上で非常に重要です。異常検出においては特に重要であり、その目的は人間が馴染みない新たな変化を検出することだからです。この場合、コンピュータは人間オペレーターに新たな異常の存在を教示する可能性もあります。または、人間が異常を無視し製品を拒否しない判断を下すことで、コスト削減につながる可能性があります。

私たちは、サブ画像異常検出とセグメンテーションのタスクを解決するための新しい方法を提案します。私たちの方法は、拡張されたトレーニング段階を必要とせず、高速で頑健であり、最先端の性能を達成します。当手法は複数の段階から構成されます：i) 事前訓練された深層神経ネットワーク（例：ImageNetで訓練されたResNet）を用いた画像特徴抽出 ii) ターゲット画像に最も近いK個の正常画像の最近傍検索 iii) ターゲット画像と正常画像間の密な 픽セルレベル対応の検出。正常画像の検索結果に近似一致しないターゲット画像の領域は異常としてラベル付けされます。当手法は、産業製品データセット（MVTech）およびキャンパス環境の監視データセット（上海科技大学キャンパス）で広範に評価されました。当手法は、画像レベルおよび 픽セルレベルの異常検出において最先端の性能を達成しています。

2 先行研究

異常検出は、過去数十年間で多くの研究対象となってきました。本稿では、画像レベルとサブ画像レベルの異常検出手法の概要を説明します。

画像レベルの手法：画像が異常かどうかを検出する手法で、画像内の異常をセグメント化するように特別に設計されていないものをレビューします。

Although visual anomaly detection is very valuable, it is also quite challenging. One challenge common to all anomaly detection methods is the unexpectedness of anomalies. Typically in supervised classification, test classes come from the a similar distribution to the train data. In most anomaly detection settings, the distribution of anomalies is not observed during training time. Different anomaly detection methods differ by the way the anomalies are observed at training time. In this paper, we deal with the setting where at training time only normal data (but no anomalies) are observed. This is a practically useful setting, as obtaining normal data (e.g. products that contain no faults) is usually easy. This setting is sometimes called semi-supervised ([7]). As this notation is ambiguous, we shall refer to this setting as the normal-only training setting. An easier scenario is fully supervised i.e. both normal and anomalous examples are presented with labels during training. As this training setting is similar to standard supervised classification, a mature task with effective solutions, it will not be dealt with in this work.

Another challenge particular to visual anomaly detection (rather than non-image anomaly detection methods) is the localization of anomalies i.e. segmenting the parts of the image which the algorithm deems anomalous. This is very important for the explainability of the decision made by the algorithm as well as for building trust between operators and novel AI systems. It is particularly important for anomaly detection, as the objective is to detect novel changes not seen before which humans might not be familiar with. In this case, the computer may teach the human operator of the existence of new anomalies or alternatively the human may decide that an anomaly is not of interest thus not rejecting the product, resulting in cost-saving

We present a new method for solving the task of sub-image anomaly detection and segmentation. Our method does not require an extended training stage, it is fast, robust and achieves state of the art performance. Our method consists of several stages: i) image feature extraction using a pre-trained deep neural network (e.g. an ImageNet trained ResNet) ii) nearest neighbor retrieval of the nearest K normal images to the target iii) finding dense pixel-level correspondence between the target and the normal images, target image regions that do not have near matches in the retrieved normal images are labeled as anomalous. Our method is extensively evaluated on an industrial product dataset (MVTech) as well as a surveillance dataset in a campus setting (Shanghai Tech Campus). Our method achieves state-of-the-art performance both on image-level and pixel-level anomaly detection.

2 Previous Work

Anomaly detection has attracted a large body of work over the last several decades. We present an overview of image-level and sub-image anomaly detection methods.

Image-level methods: We review methods that detect if an image is anomalous that are not particularly designed for segmenting the anomaly within the image.