

これらの方法の多くは画像に特化したものではありません。画像レベル異常検出のための主要な3つの方法のクラスは、再構築ベース、分布ベース、分類ベースです。

再構築ベースの手法は、訓練データから基底関数のセットを学習し、テスト画像をこれらの基底関数の疎なセットを使用して再構築しようとします。テスト画像が基底関数で忠実に再構築できない場合、それは異常とみなされます。これは、その画像が通常の訓練データとは異なる基底から来た可能性が高いからです。異なる手法は、使用する基底関数と損失関数のセットで異なります。人気の基底関数には、K-means [15]、K最近傍法 (kNN) [9]、主成分分析 (PCA) [20] などがあります。損失関数は、ユークリッド距離や L_1 損失のような単純なベクトルメトリクスから、構造的類似性 (SSIM) [32] のようなより複雑な知覚損失まで多岐にわたります。最近、深層学習手法が再構築ベースの手法のツールボックスを拡大しています。主成分は、オートエンコーダー [27] によって学習された非線形関数に拡張されており、ノイズ除去オートエンコーダーと変分オートエンコーダー (VAE) の両方を含みます。深層知覚損失関数 [34] は、伝統的な知覚損失関数に比べて大幅に性能が向上しています。再構築ベースの損失関数の主な欠点は、i) 再構築の品質評価に用いる損失測定値に依存するため、その設計が直感的でなく性能を損なう点、ii) 正しい機能的基底を決定する点です。

2つ目の手法のクラスは分布ベースです。主な原理は、正常データの分布の確率密度関数 (PDF) をモデル化することです。テストサンプルはPDFを用いて評価され、確率密度値が低いテストサンプルは異常と指定されます。異なる分布ベースの手法は、分布の仮定、真のPDFを推定するための近似手法、およびトレーニング手順によって異なります。パラメトリック手法にはガウス分布やガウス混合モデル (GMM) が含まれます。カーネル密度推定 [21] は注目すべき非パラメトリック手法です。最近傍法 [9] も分布ベースの手法 (密度推定を行うため) と見なされますが、再構築ベースの手法としても分類されています。最近、深層学習手法は性能を向上させており、特に高次元データ分布を低次元で密な空間にマッピングすることで効果を発揮しています。PDF推定は低次元空間では一般的に容易です。深層投影と分布モデル化を同時に学習する手法は [36] で実施されています。最近のもう一つの進展である敵対的学習も、異常検出に適用されています (例: ADGAN [8])。原則として分布ベースの手法は非常に有望ですが、いくつかの重大な欠点があります: i) 実際の画像データは単純なパラメトリックな分布仮定に従うことは稀です ii) 非パラメトリック手法はサンプル複雑度が高く、実践では入手困難な大規模な訓練データセットを必要とすることが多いです。

最近、分類ベースの方法が画像レベル異常検出において主流となっています。その一例がワンクラスサポートベクターマシン (OC-SVM) [28] です。その最も成功した変種の一つがサポートベクターデータ記述 (SVDD) [30] で、これは与えられたデータの少なくとも一定割合を含む最小の球面を見つけるものと見なされます。これらの方法は非常に敏感で



Note that many of these methods are not specific to images. There are three main classes of methods for image-level anomaly detection: reconstruction-based, distribution-based and classification-based.

Reconstruction-based methods learn a set of basis functions on the training data, and attempt to reconstruct the test image using a sparse set of these basis functions. If the test image cannot be faithfully reconstructed using the basis functions, it is denoted as anomalous, as it is likely that it came from a different basis from that of the normal training data. Different methods vary in terms of the set of basis functions and loss functions they use. Popular choices of basis functions include: K-means [15], K nearest neighbors (kNN) [9], principal component analysis (PCA) [20]. The loss functions used vary between simple vector metrics such as Euclidean or L_1 losses and can use more complex perceptual losses such as structural similarity (SSIM) [32]. Recently deep learning methods have broadened the toolbox of reconstruction-based methods. Principal components have been extended to non-linear functions learned by autoencoders [27], including both denoising as well as variational autoencoders (VAEs). Deep perceptual loss functions [34] significantly improve over traditional perceptual loss functions. The main disadvantages of reconstruction-based loss functions are: i) sensitivity to the particular loss measure used for evaluating the quality of reconstruction, making their design non-obvious and hurting performance ii) determining the correct functional basis.

The second class of methods is distribution-based. The main principle is to model the probability density function (PDF) of the distribution of the normal data. Test samples are evaluated using the PDF, and test samples with low probability density values are designated as anomalous. Different distribution-based methods differ by the distributional assumptions that they make, the approximations used to estimate the true PDF, and by the training procedure. Parametric methods include Gaussian or mixture of Gaussians (GMM). Kernel density estimation [21] is a notable non-parametric method. Nearest neighbors [9] can also be seen as a distributional (as it performs density estimation), but note that we also designated it a reconstruction-based method. Recently deep learning methods have improved performance, particularly by mapping high-dimensional data distributions into a lower and denser space. PDF estimation is typically easier in lower dimensional spaces. Learning the deep projection and distributional modeling can be done jointly as done by [36]. Another recent development, adversarial training, was also applied to anomaly detection e.g. ADGAN [8]. Although in principle distributional-methods are very promising, they suffer from some critical drawbacks: i) real image data rarely follows simple parametric distributional assumptions ii) non-parametric methods have high sample complexity and often require large training set that is often not available in practice.

Recently, classification-based methods have achieved dominance for image-level anomaly detection. One such paradigm is one-class support vector machines (OC-SVM) [28]. One of its most successful variants is support vector data description (SVDD) [30] which can be seen as a finding the minimal sphere which contains at least a given fraction of the data. These methods are very sensitive to