

4 実験

私たちは、サブ画像異常検出における最先端手法との比較評価を徹底的に行います。

4.1 MVTec

産業環境での異常検出をシミュレートするため、[5] Bregmannらは、15の異なるクラスからなる画像データセットを提示しました。5つのクラスは木材や革などのテクスチャからなり、残りの10クラスは物体（主に剛体）を含みます。各クラスにおいて、トレーニングセットは正常な画像で構成されています。テストセットは、正常な画像に加え、異なる種類の異常を含む画像で構成されています。このデータセットは、訓練に異常画像を使用しない標準プロトコルに従っています。このデータセットの異常は、文献で一般的に使用されるもの（例えばCIFAR10評価における異常画像は完全に異なる画像カテゴリから抽出される）よりも細粒度です。代わりに、異常は「軽く傷ついたヘーゼルナッツ」や「軽く曲がったケーブル」のような形態をとります。異常はサブ画像レベル、つまり画像の一部のみに影響を与えるため、データセットは異常領域の正確なピクセル位置を示すセグメンテーションマップを提供します。

MVTecデータセットにおける当手法の動作例は図2に示されています。異常なオブジェクト（ヘーゼルナッツ）には傷があります。取得した近傍の正常画像には、傷のない完全なナッツが含まれています。2つの画像間の対応関係を検索することで、当手法は正常画像領域の対応関係を検出できますが、異常領域の対応関係は検出できません。これにより、画像の異常領域を正確に検出できます。異常画像のピクセルは、右端の画像に表示されています。

当社は、過去数ヶ月間で提案された複数の手法に加え、OC SVMや最近傍法などの既存の基準手法と当社の手法を比較しました。各設定において、適切なメトリクスを報告した手法と比較しました。

まず、異常な画像検出手段として深層最近傍マッチングの品質を比較します。これは、テスト画像と最も近い正常画像との距離によって計算されます。より大きな距離は、より異常な画像を示します。私たちは、私たちの方法の最初のステップと、画像レベル異常検出における他の最先端手法のROC曲線下面積（ROCAUC）を比較しました。15のクラスにわたる平均ROCAUCを報告します。注意：私たちの方法の最初の段階は、DN2 [3] と同一です。この比較は、これらのデータセットにおいて深層最近傍が有効かどうかを検証するため重要です。比較結果は表1に示されています。当手法は、自己教師付き異常検出学習技術を活用する複数の最先端手法を凌駕することが示されています。これは、ImageNet（ImageNetデータセットとは非常に異なる）で訓練された深層特徴が、ImageNetとは異なるデータセットでも非常に有効であることを示しています。

私たちは、ピクセルレベル異常検出タスクにおける手法の評価に進みます。ここでは、異常を含む特定のピクセルをセグメント化する

4 Experiments

We perform an extensive evaluation of our method against the state-of-the-art in sub-image anomaly detection.

4.1 MVTec

To simulate anomaly detection in industrial settings, [5] Bregmann et al. presented a dataset consisting of images from 15 different classes. 5 classes consist of textures such as wood or leather. The other 10 classes contain objects (mostly rigid). For each class, the training set is composed of normal images. The test set is composed of normal images as well as images containing different types of anomalies. This dataset therefore follows the standard protocol where no anomalous images are used in training. The anomalies in this dataset are more finegrained than those typically used in the literature e.g. in CIFAR10 evaluation, where anomalous images come from a completely different image category. Instead, anomalies take the form of a slightly scratched hazelnut or a lightly bent cable. As the anomalies are at the sub-image level, i.e. only affect a part of the image, the dataset provides segmentation maps indicating the precise pixel positions of the anomalous regions.

An example of the operation of our method on the MVTec dataset can be observed in Fig. 2. The anomalous object (a hazelnut) contain a scratch. The retrieved nearest neighbor normal image, contains a complete nut without scratches. By search for correspondences between the two images, our method is able to find correspondences for the normal image regions but not for the anomalous region. This results in an accurate detection of the anomalous region of the image. The anomalous images pixels are presented on the right-most image.

We compared our method against several methods that were introduced over the last several months, as well as longer standing baseline such as OCSVM and nearest neighbors. For each setting, we compared against the methods that reported the suitable metric.

We first compare the quality of deep nearest neighbor matching as a means for finding anomalous images. This is computed by the distance between the test image and the nearest neighbor normal images. Larger distances indicate more anomalous images. We compared the ROC area under the curve (ROCAUC) of the first step of our method and other state-of-the-art methods for image level anomaly detection. We report the average ROCAUC across the 15 classes. Please note that the first stage of our method is identical with DN2 [3]. This comparison is important as it verifies if deep nearest neighbors are effective on these dataset. The comparison is presented in Tab. 1. Our method is shown to outperform a range of state-of-the-art methods utilizing a range of self-supervised anomaly detection learning techniques. This gives evidence that deep features trained on ImageNet (which is very different from ImageNet dataset) are very effective even on datasets that are quite different from ImageNet.

We proceed to evaluate our method on the task of pixel-level anomaly detection. The objective here is to segment the particular pixels that contain anoma-