

図7: ナノファイバー材料のデータセットにおいて、SSIMオートエンコーダーを使用し、異なる偽陽性率における当社のセグメンテーションと真値の個々の欠陥間の領域間オーバーラップ。

15秒と55秒で単一の入力画像を処理します。

図8は、 ℓ^2 などのピクセルごとの距離よりも、知覚的誤差メトリクスを採用する定性的優位性を示しています。これは、テクスチャデータセットの1つから取得した2つの欠陥画像を示しており、上部の画像は金属ピンによる高コントラストの欠陥が生地を汚染しているものです。下部の画像は、生地が切り開かれた低コントラストの構造的欠陥を示しています。 ℓ^2 -ノルムは低コントラスト欠陥の検出に問題がありますが、背景との絶対距離が大きい金属ピンを容易にセグメント化できます。しかし、エッジ領域のずれは非欠陥領域でも大きな残差を引き起こし、実践ではこれらの薄い欠陥のセグメント化が困難になります。SSIMは、輝度、コントラスト、構造情報の同時的な注目と、パッチごとの比較によるエッジ位置のずれへの無感応性により、両方の欠陥タイプを堅牢にセグメント化します。

5. CONCLUSION

私たちは、自動エンコーダーアーキテクチャにおいて、非監督型欠陥セグメンテーションタスクに用いられる場合、パーセプチュアル損失関数が一般的に使用されるピクセル単位の残差よりも優れていることを示します。ピクセル単位の損失は、局所的な画像領域間の相互依存性を捕捉できず、欠陥が欠陥のない材料の構造的変化として現れ、ピクセルの強度値がほぼ一定のままの場合、限定的な用途しかありません。さらに、VAEから得られる確率的ピクセル単位の誤差メトリクスや、特徴マッチング正規化技術による再構築のシャープニングを採用しても、セグメンテーション結果が改善されないことを示します。これは、ピクセルを相互に独立したものと扱うことで生じる問題を解決していないためです。

SSIMは、局所的なパッチ領域の比較を行うため、エッジ位置の小さな不正確さに敏感ではなく、輝度、コントラスト、構造の3つの異なる統計的指標を考慮します。私たちは、ナノファイバー材料の挑戦的な現実世界のデータセットと、公開可能な2つの織物材料のデータセットで評価することで、ピクセル単位の損失関数から構造的類似性に基づくエラーメトリクスへの切り替えが大幅な改善をもたらすことを示します。SSIMを使用することで、ほぼ使用不能なセグメンテーションから、

Latent dimension	AUC	SSIM window size	AUC	Patch size	AUC
50	0.848	3	0.889		
100	0.935	7	0.965	32	0.949
200	0.961	11	0.966	64	0.959
500	0.966	15	0.960	128	0.966
1000	0.962	19	0.952		

表2: SSIMオートエンコーダーアーキテクチャのハイパーパラメーターを変化させた場合のNanoTWICEにおけるROC曲線下面積 (AUC)。異なる設定は欠陥セグメント化性能に有意な影響を与えません。




図8: 最初の行では、金属ピンは欠陥のない背景材料と比べて灰階値に大きな差があります。そのため、 ℓ^2 および SSIM エラーメトリクスで検出可能です。一方、2行目に示された欠陥は、絶対的な灰階値よりも構造的な違いがテクスチャと異なります。その結果、ピクセル単位の距離メトリクスは欠陥をセグメント化できませんが、SSIMは良好なセグメント化結果を得られます。

事前訓練されたネットワークなどの画像事前知識に依存する他の最先端のアプローチと肩を並べる結果へと向上します。

References

- Jinwon An and Sungzoon Cho. Variational Autoencoder based Anomaly Detection using Reconstruction Probability. *SNU Data Mining Center, Tech. Rep.*, 2015.
- Martin Arjovsky and Léon Bottou. Towards Principled Methods for Training Generative Adversarial Networks. *International Conference on Learning Representations*, 2017.
- Christoph Baur, Benedikt Wiestler, Shadi Albarqouni, and Nassir Navab. Deep Autoencoding Models for Unsupervised Anomaly Segmentation in Brain MR Images. *arXiv preprint arXiv:1804.04488*, 2018.
- Giacomo Boracchi, Diego Carrera, and Brendt Wohlberg. Novelty Detection in Images by Sparse Representations. In *2014 IEEE Symposium on Intelligent Embedded Systems (IES)*, pages 47–54. IEEE, 2014.
- Diego Carrera, Giacomo Boracchi, Alessandro Foi, and Brendt Wohlberg. Detecting anomalous structures by convolutional sparse models. In *2015 International Joint Conference on Neural Networks (IJCNN)*, pages 1–8. IEEE, 2015.
- Diego Carrera, Giacomo Boracchi, Alessandro Foi, and Brendt Wohlberg. Scale-invariant anomaly detection with multiscale group-sparse models. In *2016 IEEE International Conference on Image Processing (ICIP)*, pages 3892–3896. IEEE, 2016.
- Diego Carrera, Fabio Manganini, Giacomo Boracchi, and Ettore Lanzarone. Defect Detection in SEM Images of Nanofibrous Materials. *IEEE Transactions on Industrial Informatics*, 13(2):551–561, 2017.




Figure 7: Per-region overlap for individual defects between our segmentation and the ground truth for different false positive rates using an SSIM autoencoder on the dataset of nanofibrous materials.

15 s and 55 s to process a single input image.

Figure 8 depicts qualitative advantages that employing a perceptual error metric has over per-pixel distances such as ℓ^2 . It displays two defective images from one of the texture datasets, where the top image contains a high-contrast defect of metal pins which contaminate the fabric. The bottom image shows a low-contrast structural defect where the fabric was cut open. While the ℓ^2 -norm has problems to detect the low-contrast defect, it easily segments the metal pins due to their large absolute distance in gray values with respect to the background. However, misalignments in edge regions still lead to large residuals in non-defective regions as well, which would make these thin defects hard to segment in practice. SSIM robustly segments both defect types due to its simultaneous focus on luminance, contrast, and structural information and insensitivity to edge alignment due to its patch-by-patch comparisons.

5. CONCLUSION

We demonstrate the advantage of perceptual loss functions over commonly used per-pixel residuals in autoencoding architectures when used for unsupervised defect segmentation tasks. Per-pixel losses fail to capture interdependencies between local image regions and therefore are of limited use when defects manifest themselves in structural alterations of the defect-free material where pixel intensity values stay roughly consistent. We further show that employing probabilistic per-pixel error metrics obtained by VAEs or sharpening reconstructions by feature matching regularization techniques do not improve the segmentation result since they do not address the problems that arise from treating pixels as mutually independent.

SSIM, on the other hand, is less sensitive to small inaccuracies of edge locations due to its comparison of local patch regions and takes into account three different statistical measures: luminance, contrast, and structure. We demonstrate that switching from per-pixel loss functions to an error metric based on structural similarity yields significant improvements by evaluating on a challenging real-world dataset of nanofibrous materials and a contributed dataset of two woven fabric materials which we make publicly available. Employing SSIM often achieves an enhancement from almost unusable segmentations to results that are on par with other state of the art approaches

Latent dimension	AUC	SSIM window size	AUC	Patch size	AUC
50	0.848	3	0.889		
100	0.935	7	0.965	32	0.949
200	0.961	11	0.966	64	0.959
500	0.966	15	0.960	128	0.966
1000	0.962	19	0.952		

Table 2: Area under the ROC curve (AUC) on NanoTWICE for varying hyperparameters in the SSIM autoencoder architecture. Different settings do not significantly alter defect segmentation performance.




Figure 8: In the first row, the metal pins have a large difference in gray values in comparison to the defect-free background material. Therefore, they can be detected by both the ℓ^2 and the SSIM error metric. The defect shown in the second row, however, differs from the texture more in terms of structure than in absolute gray values. As a consequence, a per-pixel distance metric fails to segment the defect while SSIM yields a good segmentation result.

for unsupervised defect segmentation which additionally rely on image priors such as pre-trained networks.

References

- Jinwon An and Sungzoon Cho. Variational Autoencoder based Anomaly Detection using Reconstruction Probability. *SNU Data Mining Center, Tech. Rep.*, 2015.
- Martin Arjovsky and Léon Bottou. Towards Principled Methods for Training Generative Adversarial Networks. *International Conference on Learning Representations*, 2017.
- Christoph Baur, Benedikt Wiestler, Shadi Albarqouni, and Nassir Navab. Deep Autoencoding Models for Unsupervised Anomaly Segmentation in Brain MR Images. *arXiv preprint arXiv:1804.04488*, 2018.
- Giacomo Boracchi, Diego Carrera, and Brendt Wohlberg. Novelty Detection in Images by Sparse Representations. In *2014 IEEE Symposium on Intelligent Embedded Systems (IES)*, pages 47–54. IEEE, 2014.
- Diego Carrera, Giacomo Boracchi, Alessandro Foi, and Brendt Wohlberg. Detecting anomalous structures by convolutional sparse models. In *2015 International Joint Conference on Neural Networks (IJCNN)*, pages 1–8. IEEE, 2015.
- Diego Carrera, Giacomo Boracchi, Alessandro Foi, and Brendt Wohlberg. Scale-invariant anomaly detection with multiscale group-sparse models. In *2016 IEEE International Conference on Image Processing (ICIP)*, pages 3892–3896. IEEE, 2016.
- Diego Carrera, Fabio Manganini, Giacomo Boracchi, and Ettore Lanzarone. Defect Detection in SEM Images of Nanofibrous Materials. *IEEE Transactions on Industrial Informatics*, 13(2):551–561, 2017.