

図7：MVTEC-ADにおける勾配ノイズ除去プロセスの中間ステップの可視化。1列目と2列目は異常の真値と再構築対象の画像です。最後の列は異常画像からの再構築結果です。中間列にはノイズ除去勾配プロセスの中間結果が表示されています。私たちの再構築プロセスが異常のない高品質な画像を生成し、正常ピクセルの高周波詳細を維持できることを示しています。

画像に続き、当社の勾配ノイズ除去プロセスの中間結果を示します。異常ピクセルは勾配と拡散ステップにより徐々に除去されます。提案する再構築プロセスが、元の異常画像との強い対応性を維持しつつ、正常領域の視覚的外観をほとんど変更せずに正常画像を生成できることを示します。

私たちは、再構築結果を過去の異常検出手法であるDRAEM [40]とUniAD [36]と比較しました。図4に示すように、DRAEMはアーティファクトを生成し、異常なピクセルを除去できません。UniADはVAEデコーダーで結果を再構築するため、正常領域の外観が変化し、ぼやけてしまいます。私たちの勾配ノイズ処理は、異常なピクセルと正常なピクセルの両方の再構築結果を大幅に改善します。

5. Conclusions

本研究では、再構築ベースの異常検出の性能を向上させるためのノイズ除去拡散モデルを提案します。当モデルは、ピクセルレベルと特徴量レベルの再構築誤差を異常スコアとして組み合わせます。

拡散モデルからのKLダイバージェンスを用いて、境界を意識した結果を生成し、より精度の高い局所化を実現します。さらに、当モデルは事前訓練された深層特徴抽出器から勾配をノイズ除去することで、異常画像を高品質な正常画像に再構築でき、従来の再構築結果を大幅に上回ります。また、当再構築ベースのノイズ除去拡散モデルがさまざまな異常タイプに頑健であり、すべてのカテゴリに対応する統一的な異常検出器として拡張可能であることを示します。

議論 当社のアプローチは、ノイズ除去の観点から異常局所化問題に取り組んでいます。MVTEC-ADデータセットには背景領域に多くのノイズが含まれており、当社のノイズ除去モデルによって異常として容易に検出されるため、画像レベルAUROC指標で3%の性能低下を引き起こしています。

謝辞 本研究は、研究助成金理事会 (Research Grants Council) の「Excellence Areas」プログラム助成金AoE/E-601/22-Rおよび深セン科学技術プログラムKQTD20210811090149095の支援を受けて実施されました。




Figure 7: Visualization of the intermediate steps of denoising gradient process on MVTecAD. The 1st and 2nd columns are the ground truth of anomalies and the image to be reconstructed. The last column is the reconstructed results from the anomalous image. The intermediate results of the denoising gradient process are shown in the middle columns. We show that our reconstruction process can generate high-quality anomaly-free images and keep high-frequency details of normal pixels.

image, followed by the intermediate results from our gradient denoising process. The anomalous pixels are gradually removed by the gradients and diffusion steps. We show that the proposed reconstruction process can generate normal images with strong correspondence to the original anomalous image, while keeping most visual appearances of normal regions unchanged.

We compare the reconstruction results with previous anomaly detection methods, DRAEM [40] and UniAD [36]. As Fig. 4 shows, the DRAEM generates artifacts and fails to remove the anomalous pixels. The appearance of normal regions is changed and blurred by UniAD since it reconstructs the results with a VAE decoder. Our gradient noising process greatly improves the reconstruction results for both anomalous and normal pixels.

5. Conclusions

In this work, we propose a denoising diffusion model to boost the performance of reconstruction-based anomaly localization. Our model combines pixel-level and feature-

level reconstruction errors as the anomaly score. We use the KL divergence from the diffusion model to produce boundary-aware results for better localization. Moreover, our model can reconstruct anomalous images to a high-quality normal image by denoising the gradients from a pre-trained deep feature extractor, surpassing the previous reconstruction results by a large margin. We also demonstrate that our reconstruction-based denoising diffusion model is robust to various anomaly types and can be extended as a unified anomaly detector for all categories.

Discussions Our approach addresses the anomaly localization problem from a denoising perspective. The MVTecAD dataset contains many noises in the background regions, which are easily detected as anomalous by our denoising model, causing a 3% performance drop on the image-level AUROC metric.

Acknowledgement The work was supported in part by the Research Grants Council under the Areas of Excellence scheme grant AoE/E-601/22-R and Shenzhen Science and Technology Program KQTD20210811090149095.