

1クラス埋め込みからの逆蒸留による異常検出

鄧漢秋

リー・シンユー

アルバータ大学電気・コンピュータ工学部

{hanqiu1,xingyu}@ualberta.ca

抽象的な

知識蒸留 (KD)は有望な結果を達成
教師なし異常検出 (AD)という困難な問題に関する。異常の表現の不一致は、
教師-生徒 (TS)モデルは重要な証拠を提供する
AD向け。ただし、類似または同一のアーキテクチャを使用して
これまでの研究で教師と生徒のモデルを構築することは、異常な表現の
多様性を阻害する。
この問題に対処するために、教師エンコーダと生徒デコーダで
構成される新しいTSモデルを提案し、シンプルだが効果的な
「逆蒸留」パラダイムを導入する。
それに応じて、生の画像を直接受け取る代わりに、
学習ネットワークは教師モデルの1クラス埋め込みを入力として受け取り、教
師のマルチスケール表現を復元する。本質的に、学習ネットワークにおける知
識蒸留は
この研究は抽象的で高度なプレゼンテーションから始まり、
低レベルの特徴。さらに、学習可能な
TSの1クラスボトルネック埋め込み (OCBE)モジュール
モデル。得られたコンパクトな埋め込みは、正常パターンに関する重要
な情報を効果的に保存する一方で、異常な摂動を放棄する。

ADと1クラスの新規性検出ベンチマークでは、
私たちの方法はSOTAのパフォーマンスを上回り、
私たちが提案したアプローチの有効性と一般化可能性。

1. はじめに

異常検出 (AD)とは、事前の知識が限られている、あるいは全くない
状態で異常を識別し、その場所を特定することを指します。
異常を検知する。ADは、産業用欠陥検出[3]、医療用流通外れ検出[50]、
ビデオ監視[24]など幅広い用途があり、重要な技術となっている。

タスクとスポットライトの両方の役割を担う。監督なしの
ADでは、異常に関する事前情報は提供されていません。代わりに、
参考として正常なサンプルセットが提供されます。
この問題に対処するために、これまでの取り組みでは、
これらの異常のないサンプルに対して、様々な自己教師タスクを実行す
る。これらのタスクには、サンプル再構成[2,5,11,16,26,34,38,48]、疑似
外れ値拡張などが含まれるが、これらに限定されない。




図1. MVTec [3]における異常検出の例。マルチ解像度知識蒸留 (MKD) [33]は、図2(a)に示す従来のKDアーキテクチャを採用している。我々の逆蒸留は、この方法は、さまざまな異常を正確に特定することができます。

ステーション[23,42,46]、知識蒸留[4,33,39]など。
この研究では、教師なし学習の問題に取り組みます。

知識蒸留に基づく異常検出
視点。知識蒸留 (KD) [6, 15]では、
知識は教師と生徒 (TS) のペア内で伝達されます。
教師なしADの文脈では、学習者は訓練中に通常のサンプルのみを経験
するため、
教師から矛盾した表現を生成する
クエリが異常である。この仮説は、
KDベースの異常検出手法。しかし、これは
この仮説は、実際には必ずしも正しいとは限らない。その理由は (1)
教師と生徒の同一または類似のアーキテクチャ
ネットワーク (すなわち、非識別フィルタ[33])と (2)
知識蒸留/蒸留におけるTSモデル内のデータフローは同じです。小規模
な学生ネットワークの使用は、
この問題を部分的に解決している[33, 39]が、浅いアーキテクチャの
弱い表現能力がモデルの妨げとなっている。
異常を正確に検出し、その位置を特定します。

上記の問題を総合的に解決するために、私たちは
知識蒸留の新しいパラダイムを提案する。
逆蒸留法は異常検知に有効です。図2の簡単な図を用いて、従来の知識
蒸留法と逆蒸留法の体系的な違いを強調しています。

逆蒸留を提案した。まず、従来の方法とは異なり、
教師と
学生はエンコーダ構造を採用し、TSモデルは




図2: (a)従来のKDフレームワーク[6, 33]と(b)我々の逆蒸留パラダイムにおけるTSモデルとデータフロー。

逆蒸留は異種のアーキテクチャで構成されます。教師エンコーダと生徒デコーダ。第二に、代わりに生データをTSモデルに直接入力すると同時に、生徒デコーダは低次元埋め込みを入力として受け取り、教師の行動を模倣することを目指します。

教師モデルの表現を異なるスケール。[6] 回帰の観点から見ると、逆蒸留は生徒ネットワークを用いて教師モデルの表現を予測する。したがって、ここでの「逆」とは、教師エンコーダと生徒デコーダの逆の形状と、明確な知識蒸留順序の両方を意味する。

ここではまず高レベルの表現が抽出され、その後低レベルの特徴。我々の逆蒸留には2つの大きな利点があることは注目に値する。i) 非類似性構造。提案されたTSモデルでは、教師エンコーダをダウンサンプリングフィルタ、生徒デコーダをアップサンプリングフィルタとして用いる。この「逆構造」は、前述したように、非識別フィルタ[33]による混乱を回避する。ii) コンパクトネス埋め込み。生徒に入力される低次元埋め込みは、

デコーダは正常パターンの復元における情報ボトルネックとして機能します。異常な特徴を正常パターンへの摂動として定式化しましょう。そして、コンパクトな埋め込みは学生モデルへのそのような異常な摂動の伝播を阻止し、TSモデルの

異常の表現の不一致。特に、従来のAEベースの手法[5, 11, 16, 26]は、異常を検出する。ピクセルの違いを利用するのに対し、我々は密な記述的特徴を用いて識別を行う。深層特徴として領域認識記述子は、画像内のピクセルごとよりも効果的な識別情報を提供します。

さらに、ボトルネック埋め込みのコンパクトさは異常検出に非常に重要であるため（前述の通り）、1クラスボトルネック埋め込み（OCBE）を導入する機能コードをさらに圧縮するためのモジュール。当社のOCBEモジュールはマルチスケール特徴融合（MFF）ブロックで構成されているおよび1クラス埋め込み（OCE）ブロックは、どちらも学生用デコーダと共同で最適化されています。特に前者は、低レベルと高レベルの両方の特徴を集約して、通常パターンの再構成のための豊富な埋め込みを構築します。後者は、

生徒が教師の返答を解釈するのに有利な重要な情報を保持する。

公開ベンチマークを用いて広範な実験を行いました。実験結果から、逆蒸留パラダイムは従来技術と同等の性能を達成することが示されました。提案されたOCBEモジュールはさらに

パフォーマンスを最新技術（SOTA）に向上記録。私たちの主な貢献は以下のようにまとめられます。

- 異常検知のためのシンプルかつ効果的な逆蒸留パラダイムを紹介し、エンコーダ・デコーダ構造と逆知識蒸留
- 戦略は、従来のKDモデルにおける非識別フィルタ問題を全体的に解決し、TSモデルの異常識別能力。
- 教師の高次元特徴を投影するための1クラスボトルネック埋め込みモジュールを提案するコンパクトな1クラス埋め込み空間への変換。この革新により、リッチでありながらコンパクトなコードを保持することが可能になります。学生における異常のない表現の復元。
- 広範囲にわたる実験を実施し、このアプローチにより、新しい SOTA パフォーマンスが実現されます。

2. 関連研究

このセクションでは、教師なし異常検知に関するこれまでの取り組みを簡単に振り返ります。提案方法と従来技術との違い。

従来の異常検出法は、定義に重点を置いています。正規サポートベクトルを用いたコンパクトな1クラス閉分布。先駆的な研究には1クラスサポートが含まれる。ベクターマシン（OC-SVM）[35]およびサポートベクターデータ記述（SVDD）[36]。高次元に対応するためにデータ、DeepSVDD [31]および PatchSVDD [43] の推定データディープネットワークを通じた表現。

もう一つの教師なしADのプロトタイプは、サンプル再構成にオートエンコーダ（AE）[19]や生成敵対的ネットワーク（GAN）[12]などの生成モデルを用いるものである。これらの手法は、正常サンプルで学習した生成モデルは異常のない領域のみを正常に再構成できるが、異常のある領域では失敗するという仮説に基づいている[2, 5, 34]。しかし、最近の研究では、

深層モデルは一般化が非常に優れているため、異常領域であっても適切に復元できる[46]。この問題に対処するために、記憶メカニズム[11, 16, 26]、画像マスキング戦略[42, 46]、疑似異常[28, 45]が組み込まれている再構成に基づく手法では、しかしながら、これらの手法は現実世界の物体に対する強力な識別能力を欠いている。異常検出[3, 5]。最近では、Metaformer（MF）[40]メタ学習[9]を用いて、再構成に基づくアプローチにおけるモデル適応と再構成のギャップを埋めることを提案している。特に、提案されている逆知識蒸留もエンコーダ・デコーダアーキテクチャを採用しているが、

建設ベースの方法とは2つの点で異なります。まず、生成モデルのエンコーダは、デコーダーを逆蒸留し、事前学習済みのモデルを教師として用いる。第二に、ピクセルレベルの再構成エラーではなく、セマンティック特徴空間上で異常検出を行う。

データ拡張戦略も広く利用されている。提供された異常のない領域に疑似異常を追加するサンプルごとに、教師なしタスクは教師ありタスクに変換されます。学習課題[23, 42, 46]。しかし、これらのアプローチは疑似外れ値に偏りがちで、異常の種類は多種多様である。例えば、CutPaste [23] 通常画像に小さなパッチを追加することで疑似外れ値を生成し、これらの異常を検出するモデルをトレーニングする。領域。このモデルはエッジの不連続性やテクスチャの乱れなどの局所的な特徴の検出に重点を置いているため、図6に示すように、大きな欠陥や全体的な構造異常を検出して特定することができません。

最近、大規模なデータセットで事前学習されたネットワークは識別特徴を抽出できることが証明されている。異常検出のための[7,8,23,25,29,30]。事前学習済みのモデルでは、異常のない特徴を記憶することで、異常なサンプルを識別するのに役立つことが報告されている[7, 29]。 [8, 30]の研究では、マハラノビス距離を使用して異常と異常のない特徴間の類似性を測定すると、

正確な異常検出には、これらの手法は訓練サンプルからすべての特徴を記憶する必要があるため、計算コストが高い。

事前学習済みモデルからの知識蒸留は、異常検出のもう一つの潜在的な解決策です。教師なし学習の文脈では、知識蒸留において学習モデルは異常のないサンプルにさらされるため、

TSモデルは矛盾する特徴を生成することが予想される推論における異常性について[4,33,39]。TSモデルの様々なタイプの識別能力。異常の検出には様々な戦略が導入されている。例えば、マルチスケールの異常を捉えるために、US [4]は異なるスケールの正常データで訓練した複数のモデルを組み合わせている。MKD [33]は、多段階の特徴量を使用することを提案している。配置。提案されているこの方法は知識の蒸留に基づいており、私たちの逆蒸留はエンコーダとデコーダを採用した最初のTSモデルを構築する。教師の異質性。学生ネットワークと知識の逆データフロー。蒸留は、私たちの方法を従来技術と区別するものです。

3. 私たちのアプローチ

問題の定式化:私は $\mathcal{I} = \{I_1, \dots, I_n\}$ 、それは集合ではない利用可能な異常のない画像と、正常と異常の両方の $\mathcal{Q} = \{Q_1, \dots, Q_m\}$ サンプルを含むクエリセットを $\mathcal{I} \cup \mathcal{Q}$ とする。目標は、モデルを訓練して、異常箇所を認識し、位置を特定することである。クエリセット内の異常を検出します。異常検出設定では、両方の \mathcal{I} の正常なサンプル I_i 、そして \mathcal{Q} は同じ分布に従う

分布外のサンプルは異常とみなされます。システム概要:図3は提案された予備力を示している。異常検出のための蒸留フレームワーク。私たちの逆蒸留フレームワークは3つのモジュールで構成されています。固定事前学習済みの教師エンコーダE、学習可能な1クラスボトルネック埋め込みモジュール、および生徒デコーダD。入力サンプル $I \in \mathcal{I}$ 、教師Eは多尺度表現を抽出します。生徒Dに学習させることを提案します。ボトルネック埋め込みから特徴を復元する。テスト/推論中に、

教師Eは、異常なサンプルにおける異常な分布外の特徴を捉えることができる。しかし、生徒のデコーダーはDはこれらの異常な特徴を再現できず、対応する埋め込み。提案されたTSモデルにおける異常な表現の類似性が低いことは、高い異常スコア。我々は、異質なエンコーダとデコーダの構造、そして逆知識蒸留の順序は、異常の表現の矛盾に大きく寄与している。さらに、学習可能なOCBEモジュールは

マルチスケールパターンをさらに極端に凝縮し下流の正常表現の再構築のための低次元空間。これにより、教師モデルによって生成された異常表現はOCBEによって破棄される可能性が高いため、TSモデルにおける異常な特徴の不一致がさらに改善されます。このセクションの残りの部分では、まず以下を具体的に説明します。

逆蒸留パラダイムについて説明し、OCBEモジュール。最後に異常検出と予備蒸留を使用したローカリゼーション。

3.1. 逆蒸留

従来のKDでは、生徒ネットワークは教師モデルと類似または同一のニューラルネットワークを採用し、生データや画像を入力として学習し、その特徴活性を教師の[4, 33]と一致させる。1クラス学習の文脈では、教師なしADの蒸留では、学生モデルは教師なしADとは非常に異なる表現を生成することが期待されます。クエリが異常なサンプルである場合、教師は学習を中断する。 [11, 26] しかし、異常の活性化の不一致は消える時には異常検出の失敗につながる。この問題は、教師と生徒のネットワークと、同じデータフローがTS知識移転。未知の分布外サンプルにおけるTSモデルの表現多様性を向上させるために、我々は新たな埋蔵量蒸留パラダイムを提案する。

TSモデルはエンコーダ・デコーダアーキテクチャを採用しており、知識は教師の深層から抽出され、その初期の層、すなわち高レベルの意味的知識はまず学生に伝達されます。さらに、1クラス蒸留を容易にするために、訓練可能なOCBEモジュールを設計しました。教師モデルと生徒モデルを接続する（セクション3.2）。逆蒸留パラダイムでは、教師エンコーダEは包括的な表現を抽出することを目指しています。先行研究に倣い、画像認識における事前学習済みのエンコーダを使用します。

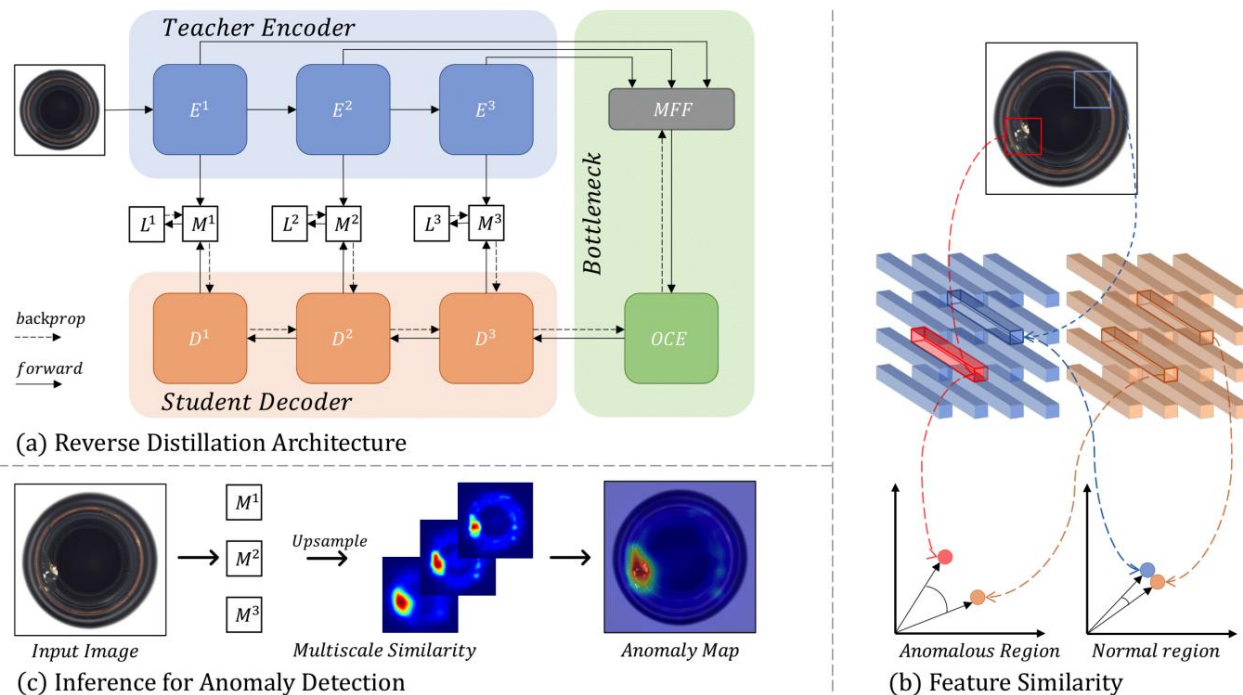


図3. 異常検知と位置特定のための逆蒸留フレームワークの概要。(a) 我々のモデルは、事前学習済みの教師エンコーダE、学習可能な1クラスボトルネック埋め込みモジュール (OCBE)、および生徒デコーダD。マルチスケール特徴を使用する。Eから低レベルと高レベルの機能をアンサンブルし、1クラス埋め込み (OCE)によってコンパクトなコードにマッピングする融合 (MFF)ブロック。訓練中、学習者Dは類似度損失Lを最小化することで学習者Eの行動を模倣する。(b)推論中、学習者Eは特徴を忠実に抽出するのに対し、Dは異常のない特徴を出力します。対応する特徴ベクトル間の類似度が低い場合、EとDの位置は異常を示唆しています。(c)最終的な予測は、マルチスケール類似性マップMの蓄積によって計算されます。

geNet [21]をバックボーンとして採用 E. TSモデルを回避する

自明な解に収束し、教師Eのすべてのパラメータ

知識の蒸留中に凍結される。

ResNet [14]とWideResNet [44]の両方でアブレーション研究が行われた。

豊富な資源を抽出できるため、有力な候補である。

画像からの特徴[4, 8, 23, 29]。

Eの中間表現と一致させるために、学生デコーダーDのアーキテクチャは対称的だが逆になっている。

Eと比較して、逆のデザインは、

学生ネットワークの異常に対する反応、

対称性により、教師ネットワークと同じ表現次元を持つことができます。例えば、

ResNetを教師モデルとして、生徒Dは

ミラー対称性のための複数の残差のようなデコードブロック。

具体的には、ResNetにおけるダウンサンプリングは

カーネルサイズ1、ストライド1の畳み込み層によって

2の[14]。学生の対応するデコードブロックは

Dはカーネルサイズが2の逆畳み込み層[47]を採用している。

ストライドは2です。学生用デコーダーの設計に関する詳細は

補足資料に記載されています。

逆蒸留では、学生デコーダーDは

学習中の教師エンコーダEの挙動を模倣する。本研究では、異常検出のためのマルチスケール特徴量ベースの蒸留を探索する。この研究の背後にある動機は

ニューラルネットワークの浅層は、低レベル情報 (例えば、色、エッジ、テクスチャなど)の局所的な記述子を抽出する一方、深層はより広い受容野を持ち、地域的／全体的な意味的・構造的情報を特徴づけることができるという点である。つまり、TSモデルにおける低レベル特徴と高レベル特徴の類似性が低いことは、局所的な異常性を示唆している。

および地域的/世界的な構造的な外れ値です。

数学的には、は生の

データを1クラスボトルネック埋め込み空間に

TSモデルにおけるペア活性化対応は{f

Ek (l) , f_D^l = Dk ()}であり、EkとDkは

kth 教師と生徒のエンコードとデコードブロック

それぞれモデル、f_E^l, f_D^l ∈ R Ck × Hk × Wk、ここで、Ck、Hk

Wkはチャンネル数、高さ、幅を表します。

kth 層活性化テンソル。知識移転のために

TSモデルでは、コサイン類似度がKD損失として採用され、

高次元と低次元の両方の情報の関係をより正確に捉えることができるためである[37, 49]。具体的には、

特徴テンソル f_E^l と f_D^l、ベクトル的に計算する

チャンネル軸に沿ったコサイン類似度損失を計算し、

2次元異常マップ M_k ∈ R Hk × Wk :

Mkの値が大きい場合、その場所に高い異常があることを示しています。マルチスケール知識蒸留を考慮すると、学生の最適化のためのスカラー損失関数は、マルチスケール異常マップを蓄積することによって得られます。

ここでKは、

実験。

3.2. 1クラスボトルネック埋め込み

逆知識蒸留パラダイムでは、生徒モデルDは教師モデルEの表現を復元しようとするため、バックボーンの最後の符号化ブロックの活性化出力を直接Dに入力することができる。しかし、この単純な接続には2つの欠点がある。まず、

KDの教師モデルは通常、高い能力を持っています。しかし大容量モデルは豊富な特徴量を抽出するのに役立ちますが、得られる高次元記述子にはかなりの冗長性がある可能性があります。

表現は学生モデルを解釈するのに有害である
本質的な異常のない特徴。第二に、活性化
バックボーンの最後のエンコーダブロックは通常、
入力データの意味的および構造的情報。
知識蒸留の逆順に、この高レベル表現を学生デコーダーセットに直接供給する
低レベルの特徴再構成の課題。前へ
データ再構築の取り組みは通常スキップパスを導入する
エンコーダとデコーダを接続する。しかし、このアプローチは
知識蒸留ではスキップパスは機能しない
推論中に異常情報を生徒に漏らす。
1クラス蒸留における上記の最初の欠点に対処するために、学習可能な1クラス埋め込みブロックを導入する。
教師モデルの高次元表現を低次元空間に投影する。

異常な特徴は正常パターンの変動として現れる。そしてコンパクトな埋め込みは情報のボトルネックとして機能する
学生モデルへの異常な振動の伝播を阻止し、TSを向上させるのに役立ちます。

モデルの異常表現の不一致。この
この研究では、ResNet [14]の4番目の残差ブロックを
1クラスの埋め込みブロック。
低レベルの特徴の復元に関する問題に対処する
デコーダDでは、MFFブロックがマルチスケール表現を連結し、1クラス埋め込みを行う。特徴連結における表現表現の整合を実現するために、浅い特徴をストライド2の1つ以上の3×3畳み込み層でダウンサンプリングし、続いてバッチ正規化とReLU活性化関数を実行する。次に、ストライド1の1×1畳み込み層と、

relu アクティベーションは、豊富でありながらコンパクトな機能を実現するために活用されています。
図4にOCBEモジュールを示します。MFFは低レベルと高レベルの機能を集約して、豊富な画像を構築します。

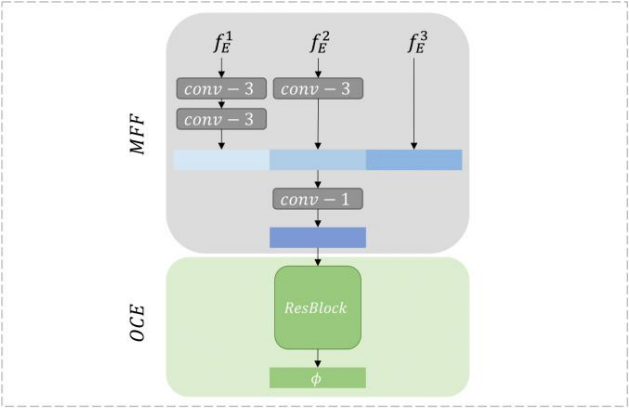


図4. 1クラスボトルネック埋め込みモジュールは、学習可能なMFFおよびOCEブロック。MFFはマルチスケールの特徴を教師EとOCEは得られた豊富な特徴をコンパクトなボトルネックコード。

通常のパターン再構築とOCEターゲットのベッディング
学生にとって有利な重要な情報を保持する
教師の応答を解釈する。畳み込み層は
図4の灰色のResBlockと緑色のResBlockは、知識学習中に学生モデルDと共同で学習および最適化される。
通常のサンプルの蒸留。

3.3. 異常スコアリング

推論段階では、まず異常箇所特定（AL）のためのピクセルレベルの異常スコアの測定を検討する。クエリサンプルが異常である場合、教師は

モデルはその特徴の異常性を反映することができます。
しかし、学生モデルは異常な場合には失敗する可能性が高い。
特徴の復元は、生徒のデコーダーが学習するだけなので、
知識蒸留におけるコンパクトな1クラス埋め込みから異常のない表現を復元する。言い換えれば、
生徒Dは、
質問が異常な場合の教師。式（1）に従うと、
TS表現から異常マップのセットを取得する
ペアであり、マップMkの値は点ごとの
kの異常
特徴テンソル。異常を局所化するために
クエリ画像では、Mkを画像サイズに合わせてアップサンプリングします。
Psiは、この計算で使用される双線形アップサンプリング演算を表す。
研究。そして、正確なスコアマップSi qiは次のように定式化される。
すべての異常マップのピクセル単位の累積：

(3)

スコアマップのノイズを除去するために、
ガウス フィルタによるSAL。
異常検出では、スコア内のすべての値を平均化する
マップSALは、小さな異常領域を持つサンプルに対しては不公平である。最も反応性の高い点は、サンプルのサイズに関係なく存在する。

画像サイズ		128				256																					
カテゴリ-/方法MKD [33]		Ours	GT [10]	GN [2]	US [4]	PSVDD [43]	DAAD [16]	MF [40]	PaDiM [8]	86.6	95.7	86.2	88.2	98.2	91.0	97.6	84.4	76.7	92.1	75.8	90.0	98.7	99.2	87.6	カットペースト[23]私たちの		
*	カーペット	79.3	99.2			43.7	69.9	91.6	92.9		85.9			94.0		99.8				93.9		98.9					
	グリッド	78.0	95.7			61.9	70.8	81.0	94.6		88.8			85.9		96.7				100		100					
	レザー	95.1	100			84.1	84.2	88.2	90.9					99.2		100				100		100					
	タイル	91.6	99.4			41.7	79.4	99.1	97.8					99.0		98.1				94.6		99.3					
	木材	94.3	98.8			61.1	83.4	97.7	96.5					99.2		99.2				99.1		99.2					
	平均	87.7	98.6			58.5	77.5	91.5	94.5					95.5		98.8				97.5		99.5					
**	ボトル	99.4	100			74.4	89.2	99.0	98.6					99.1		99.9				98.2		100					
	ケーブル	89.2	97.1			78.3	75.7	86.2	90.3					97.1		92.7				81.2		95.0					
	カプセル	80.5	89.5			67.0	73.2	86.1	76.7					87.5		91.3				98.2		96.3					
	ヘーゼルナッツ	98.4	99.8			35.9	78.5	93.1	92.0					99.4		92.0				98.3		99.9					
	金属ナット	73.6	99.2			81.3	70.0	82.0	94.0					96.2		98.7				99.9		100					
	ビール	82.7	93.3			63.0	74.3	87.9	86.1					90.1		93.3				94.9		96.6					
	スクリュー	83.3	91.1			50.0	74.6	54.9	81.3					97.5		85.8				88.7		97.0					
	歯ブラシ	92.2	90.3			97.2	65.3	95.3	100					100		96.1				99.4		99.5					
	トランジスタ	85.6	99.5			86.9	79.2	81.8	91.5					94.4		97.4				96.1		96.7					
	ジッパー	93.2	94.3			82.0	74.5	91.9	97.9					98.6		90.3				99.9		98.5					
	平均	87.8	95.4			71.6	75.5	85.8	90.8					96.0		93.8				95.5		98.0					
合計平均		87.8	96.5			67.2	76.2	87.7	92.1		89.5			95.8		95.5				96.1		98.5					

表1. MVTec [3]による異常検出結果。256×256解像度の画像の各カテゴリにおいて、上位の手法で達成された異常検出率。2つのAUROC（%）が太字で強調表示されています。テクスチャ、オブジェクト、全体の平均スコアにおいて、当社の手法が1位を獲得しました。

異常領域。したがって、最大値を定義する。
SALではサンプルレベルの異常値SADとして扱われる。直感的に
異常スコアに有意な反応が存在しないことである
通常のサンプルのマップ。

4. 実験と考察

実証的評価はMVTecの両方で実施される。
異常検出と位置特定ベンチマークと教師なし1クラス新規性検出データセット。さらに、
MVTecベンチマークでアブレーション研究を実施し、異なるモジュール/ブロックが
最終結果。

4.1. 異常検出と位置特定

データセット。MVTec [3]には15の実世界データセットが含まれている。
異常検出用。5つのテクスチャクラスと10の
オブジェクトのクラス。トレーニングセットは合計で
異常のない画像3,629枚。テストセットには異常のある画像と異常のない画像
が合計1,725枚含まれている。各クラス
テスト用の欠陥が複数あります。さらに、テストデータセットには、異常箇所の
特定評価のためのピクセルレベルの注釈が利用可能です。

実験設定。MVTec内のすべての画像は特定の解像度（例：128 × 128、
256 × 256）に合わせてサイズ変更されます。
など）。これまでの研究の慣例に従い、異常検出と位置特定は1つのカテゴリ
ごとに実行される。
この実験では、TSモデルのバックボーンEとしてWideResNet50を採用しました。
また、ADの結果も報告します。
ResNet18とResNet50を用いたアブレーション研究。
予備蒸留モデルでは、アダムオプティマイザー[18]を活用しています。
β = (0.5, 0.999) である。学習率は0.005に設定されている。
バッチサイズ16で200エポック学習する。ガウスフィルタ

σ = 4のものは異常スコアマップを平滑化するために使用される（
（3.3節で説明）
異常検出では受信機の下領域を測ります
評価指標として動作特性（AUROC）を用いる。本実験では、以下の先行技術も
考慮する。
MKD [33]、GT [10]、GANomaly（GN）[2]、無情報
学生（米国）[4]、PSVDD [43]、DAAD [16]、MetaFormer
（MF）[40]、PaDiM（WResNet50）[8]、カットペースト[23]。
異常の局在については、AUROCと
地域オーバーラップ（PRO）[4]。AUROCとは異なり、
ピクセル単位の測定に使用されるPROスコア
異常領域の大きさを等しく扱う。比較基準としては、MKD [33]、US [4]、MF
[40]、SPADEなどがある。
（WResNet50）[7,29]、PaDiM（WResNet50）[8]、RIAD [46]
およびCutPaste [23]。
実験結果と考察。MVTecにおける異常検出結果を表1に示す。平均

結果は、私たちの方法が SOTA を2.5% 上回ることを示しています。
テクスチャとオブジェクトについては、モデルは新しいSOTAを達成しました。
それぞれAUROCの99.5%と98.0%です。統計によると
異常スコアは図5に示されている。重複のない
正常（青）と異常（赤）の分布は
当社の TS モデルにおける強力な AD 機能。
異常の局在に関する定量的な結果は表2にまとめられている。AUROCと
PROの平均スコアは
すべてのカテゴリにおいて、当社のアプローチは最先端のものを超えています
97.8%と93.9%であった。
様々な異常に対する方法。我々は欠陥の種類を分類する
2つのカテゴリに分けられる：大きな欠陥または構造異常
小さな欠陥や目立たない欠陥を検出し、図6と図7の可視化によって性能を定
性的に評価します。
表1の次点（CutPaste [23]）と比較すると、
私たちの方法は、全体に対して大きな反応を生み出します

画像サイズ 128 カテゴリー/方法 MKD [33]			256													
			アワーズUS [4] MF [40] スペード [7] バディム [8] リアド [46] カットベスト [23]										98.1/95.3 -/87.8 96.3/- 97.3/92.6 -/86.5 98.8/-		私たちの	
k	カーペット 95.6/-	グリッド 91.8/-	99.0/98.6 -/95.9	99.7/97.2	99.6/84.8 -/88.1	89.1/- 92.1/82.5	99.6/84.8	85.8/- 95.5/93.2	88.6	93.9/- 98.2/94.7	98.3/-		98.9/97.0			
	レザー 98.1/-	タイル 82.8/-	木材	-/88.8	98.4/- 97.8/95.2	-/93.7	84.2/- 96.5/87.2	-/87.9	93.2/86.7	88.8/89.2	-/98.8	94.1/- 86.9	97.5/- 99.3/97.6			
	84.8/-	平均 90.6/-	ボトル 96.3/-	92.5/-	97.0/90.0 -/98.1	95.7/- 98.3/94.4	-/95.4	98.8/96.9	96.7/86.7	-/87.7	95.2/97.6	85.2/- 92.6	97.1/- 99.5/97.6			
	ケーブル 82.4/-	カパセル 95.9/-	97.0/92.3	-/93.6	97.9/69.7	6/89.4 -/90.8	94.3/- 87.4/75.9	94.1/86.0		94.9/91.1		90.5/- 95.6/90.6				
	ヘーゼルナッツ 94.6/-	金属ナット	91.1/-	88.5/87.4	94.9/91.1		95.5/-		95.3/90.9		95.3/90.9					
n	86.4/-	錠剤 89.6/-	ネジ 96.0/-	歯	92.7 -/	92.9/88.4		96.9/93.2		96.3/-		97.7/95.0				
	ブラシ 96.1/-	トランジスタ 76.5/-	ジッパー 93.9/-	平均 90.8/-	合計	93.1 -/	98.4/95.5		98.3/94.8		97.6/-		98.7/96.6			
						81.8 -/	97.2/90.9		96.7/88.8		90.0/-		97.4/91.0			
						96.8 -/	99.0/93.7		98.5/93.5		97.4/-		98.7/95.8			
						96.5 -/	99.1/95.4		98.2/92.6		97.3/-		98.9/95.5			
						94.2 -/	98.1/94.4		97.2/85.6		93.1/-		97.3/92.3			
						96.1 -/	96.5/94.6		95.7/92.7		95.7/-		98.2/96.4			
						94.2 -/	98.9/96.0		98.5/94.4		96.7/-		99.6/98.2			
						93.3 -/	97.9/93.5		98.8/93.1		98.1/-		99.1/94.5			
						66.6 -/	94.1/87.4		97.5/84.5		93.0/-		92.5/78.0			
					95.1 -/	96.5/92.6		98.5/95.9		99.3/-		98.2/95.4				
					90.8	97.6/93.4		97.8/91.6		95.8/-		97.9/93.4				
90.7/-			97.0/89.9	-/91.4	-/90.1	96.5/91.7	97.5/92.1	94.2/-	96.0/-	96.0/-		97.8/93.9				

表2. MVTec [3]におけるAUROCとPROによる異常位置特定結果。AUROCはピクセル単位の比較を表し、PROは地域ベースの行動に焦点を当てています。AUROCとPROの最良の結果を太字で示しています。注目すべきは、私たちのアプローチは堅牢で両方の指標において最先端のパフォーマンスを表します。

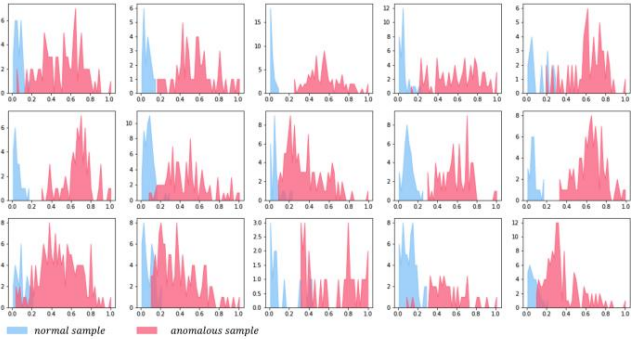


図5. すべてのカテゴリーの異常スコアのヒストグラム MVTec [3] (x軸 :0から1までの異常スコア,y軸 :カウント)。

異常領域。

複雑性分析.最近の事前学習済みモデルに基づくアプローチは抽出することで有望なパフォーマンスを実現します異常のないサンプルからの特徴を測定として用いる[7, 8]。しかし、特徴モデルを保存すると、メモリ使用量が大きくなる。消費。比較すると、私たちのアプローチはより良い追加のCNNモデルのみに依存するパフォーマンス。表3に示されている。我々のモデルは、時間とメモリの複雑さが低い。

方法	推測時間メモリパフォーマンス	
スベード (WResNet50)	1.40	1400 85.5/96.5/91.7
PaDiM (WResNet50)	0.95	3800 95.5/97.5/92.1
私たちのもの (WResNet50)	0.31	352 98.5/97.8/93.9

表3. 事前学習ベースのアプローチの比較

MVTec [3]における推論時間 (Intel i7では秒) 、メモリ使用量 (MB) 、およびパフォーマンス (AD-AUROC/AL-AUROC/AL-PRO) 。

制限事項。トランジスタデータセットにおける位置推定性能は、

良好なADパフォーマンス。このパフォーマンスの低下は予測と注釈の間の誤解によって。図6に示すように、私たちの方法は位置ずれした領域を特定し、グラウンドトゥールズは、誤った場所とオリジナルの場所の両方をカバーしていますこの問題を軽減するには、より多くの文脈的な関係を持つ特徴。経験的により広い知覚視野を持つ高レベルの特徴レイヤーパフォーマンスを向上させることができます。例えば、第2層と第3層の特徴を用いた異常検出では94.5%を達成しました。AUROCは、第3層のみを使用しながら、パフォーマンスを97.3%まで向上させました。さらに、画像解像度を下げること、128×128でもAUROC97.6%を達成しています。異常検出と位置特定の両方の事例は肯定的補足資料には肯定的および否定的な意見が記載されています。

4.2. 1クラスの新規性検出

提案手法の一般性を評価するために、3つの意味的モデルに対して1クラスの新規性検出実験を行った。データセット[32]、MNIST [22]、FashionMNIST [41]、CIFAR10 [20]などである。MNISTは手書き数字データセットであり、0~9の数字。FashionMNISTは10個の画像で構成されていますファッション製品クラス。どちらのデータセットも、学習用に6万サンプル、テスト用に1万サンプルが含まれており、解像度はすべて28×28です。CIFAR10は、学習に非常に難しいデータセットです。多様な自然物が含まれているため、新規性検出に優れています。5万枚のトレーニング画像と1万枚のテスト画像が含まれています。32 × 32のスケールの画像が10のカテゴリに分類されています。

[27]で述べたプロトコルに従って、我々は単一クラスのサンプルでモデルを作成し、新規の検出を行うサンプル。新規性スコアは、




図6. 上から下への異常:「金属ナット」の「反転」、
「トランジスタ」に「misplaced (置き忘れ)」、そして「ヘーゼルナッツ」に「crack (ひび割れ)」。通常
サンプルは参考として提供されます。




図7. 小さな、あるいは目立たない異常の可視化。
左から右へ: カーペット、タイル、木材、ケーブル、鋏、歯ブラシ、ネジ。

方法	MNIST	F-MNIST	CIFAR10	カリフォルニア工科大学-256
LSA [1]	97.5	92.2	64.1	-
オガン[27]	97.3	87.8	65.7	-
HRN [17]	97.6	92.8	71.3	-
DAAD [16]	99.0	-	75.3	-
MKD [33]	98.7	94.5	84.5	-
G2D [28]	-	-	-	95.7
OiG [45]	-	-	-	98.2
私たちの	99.3	95.0	86.5	99.9

表 4. 1 クラス新規性検出の AUROC(%) 結果。
最良の結果は太字でマークされます。

類似度マップのスコア。この実験のベースラインには、LSA [1]、OCGAN [27]、HRN [17]、DAAD [16]およびMKD [33]との比較も記載した。
Caltech-256 [13]のOiG [45]とG2D [28]。

表4は、3つの項目の定量的結果をまとめたものである。
データセット。驚くべきことに、私たちのアプローチは優れた結果を生み出しました。実験の詳細とクラスごとの結果
比較は補足資料に記載されています。

4.3. アブレーション分析

OCEブロックとMFFブロックの効果を調査する
ADを計算し、表5に数値結果を報告します。

事前学習済みの残差ブロック[14]をベースラインとして用いる。埋め込み
事前学習済みの残差ブロックには異常な特徴が含まれる可能性があり、これによりTSモデルの表現の不一致が減少します。当社の学習可能なOCEブロックは、特徴コードを凝縮します。
MFF ブロックは豊富な機能を埋め込みに融合し、より正確な異常検出と位置特定を可能にします。

メトリック	前	ブレOCE	ブレ+OCE+MFM
オーロキヤド	96.0	97.9	98.5
オーロカル	96.9	97.4	97.8
RP O	91.2	92.4	93.9

表 5. 事前トレーニング済みのボトルネック、OCE、および MFF のアブレーション研究。

表6は、教師モデルとして異なるバックボーンネットワークを定性的に比較したものです。直感的に、より深い
より広いネットワークは通常より強力な代表者を持つ
容量により、異常を正確に検出できるようになります。
注目すべきは、このような小さなニューラルネットワークでも
ResNet18と同様に、私たちの逆蒸留法は依然として
素晴らしいパフォーマンス。

バックボーン	ResNet18	ResNet50	WResNet50
オーロキヤド	97.9	98.4	98.5
オーロカル	97.1	97.7	97.8
RP O	91.2	93.1	93.9

表 6. 異なるバックボーンとの定量的な比較。

さらに、異なるネットワーク層が異常検出に与える影響についても調査し、その結果を次のように示しました。

表7. 単層構造の場合、M2が最良の結果をもたらす
局所的なテキストチャと全体的な構造情報の両方をトレードオフするからです。マルチスケール特徴融合は、より多くの情報をカバーするのに役立ちます。
異常の種類。

スコアマップ	M1	M2	M3	M2,3	M1,2,3
AUROC 90.1	AUROC 94.0	97.5	97.2	98.0	98.5
RP O 88.6		96.9	96.9	97.6	97.8
		92.6	89.5	93.2	93.9

表 7. マルチスケール特徴蒸留に関するアブレーション研究。

5. 結論

私たちは新しい知識蒸留パラダイムを提案しました。
逆蒸留法を用いて異常検出を行う。これは、従来のKDベースのAD手法の問題点を総合的に解決し、
TSモデルの異常に対する反応を強化した。さらに、
逆蒸留において、学習可能な1クラス埋め込みとマルチスケール特徴融合ブロックを導入し、
1クラスの知識移転。実験により、
この方法は、異常性において従来の技術を大幅に上回った
検出、異常箇所の特定、新規性の検出。

参考文献

[1] ダヴィデ・アバティ、アンジェロ・ポレツコ、シモーネ・カルデラーラ、リタ Cucchiara. 潜在空間自己回帰による新規性検出. IEEE/CVF コンピュータビジョンとパターン認識会議論文集, 481–490ページ, 2019.

8

[2] Samet Akcay, Amir Atapour-Abarghouei, Toby P. Breckon. Ganomaly: 半教師あり異常検出 敵対的トレーニングを通じて. CV Jawahar, Hongdong Li, グレグ・モリ、コンラッド・シンドラー、コンピュータビジョン編集者 – ACCV 2018, 622 ~ 637ページ, Cham, 2019年. Springer International Publishing. 1.2.6

[3] ポール・バークマン、マイケル・ファウザー、デイヴィッド・サトレッガー、カーステン・シュテガー. MVTEC広告 – 包括的な現実世界 教師なし異常検出のためのデータセット. Proceedingsに掲載 IEEE / CVF コンピュータビジョンとパターン認識会議 (CVPR) . 2019年6月. 1.2.6.7

[4] ポール・バークマン、マイケル・ファウザー、デイヴィッド・サトレッガー、カーステン・シュテガー. 無知な生徒 : 生徒と教師 識別的潜在埋め込みによる異常検出。 IEEE/CVF コンピュータビジョンとパターン認識会議 (CVPR) の議事録. 2020 年6月. 1.3.4.6、

7

..

[5] ポール・バークマン、シンディ・ロウ、マイケル・ファウザー、デイヴィッド・サトレッガー、カーステン・シュテガー. オートエンコーダへの構造類似性の適用による教師なし欠陥セグメンテーションの改善、 2018年1月2日

[6] 陳彭光、劉秀、趙恒双、賈佳雅。 知識レビューによる知識の抽出. Proceedingsに掲載 IEEE/CVF コンピュータビジョンとパターン認識会議、5008~5017ページ、2021 年. 1, 2

[7] Niv CohenとYedid Hoshen. サブイメージ異常検出 深いピラミッドの対応を持つ、 2020年. 3.6.7

[8] トーマス・デファール、アレクサンドル・セトコフ、アンジェリーク・レッシュ、ロマリック・オーディジェ。 Padim: パッチ配布モデリング 異常検知と位置特定のためのフレームワーク. 国際パターン認識会議、475~ 489ページ。 シュプリンガー、 2021年. 3.4.6.7

[9] Chelsea Finn, Pieter Abbeel, Sergey Levine. 深層ネットワークの高速適応の ためのモデルに依存しないメタ学習。 機械学習に関する国際会議のページ 1126–1135. PMLR, 2017. 2

[10] イザク・ゴランとラン・エルヤニフ「幾何学的変換を用いた深層異常検出」第32回 人工知能学会大会論文集 神経情報処理に関する国際会議 システム、NIPS'18, 9781~9791ページ、レッドフック、ニューヨーク州、米国、 2018. カランアソシエイツ社 6

[11] Dong Gong, Lingqiao Liu, Vuong Le, Budhaditya Saha, ムーサ・レダ・マンスール、スヴェータ・ベンカデシュ、アントン ファン・デン・ヘンゲル. 異常を検知するために正常状態を記憶する : 教師なし学習のためのメモリ拡張型ディープオートエンコーダ 異常検出. IEEE/CVF 国際コンピュータビジョン会議 (ICCV) の議事録. 2010年 10月 2019年. 1.2.3

[12] イアン・J・グッドフェロー、ジャン・ブージェ=アバティ、メディ・ミルザ、ビング 徐、デビッド・ウォード・ファリー、シェール・オゼール、アーロン・クルヴィル、そして ヨシュア・ベンジオ「生成的敵対的ネットワーク」。Proceedings掲載

第27回国際神経情報会議 処理システム - 第2巻、NIPS'14, 2672~2680ページ、 ケンブリッジ、マサチューセッツ州、米国、2014年. MIT プレス. 2

[13] グレゴリー・グリフィン、アレックス・ホルプ、ビエトロ・ペローナ. Caltech-256 オブジェクトカテゴリデータセット. 2007年8月

[14] 何開明、張祥宇、任少青、孫建。 画像認識のための深層残差学習. IEEE コンピュータビジョンとパターンに関す る会議の議事録 認識 (CVPR) . 2016年6月. 4.5.8

[15] ジェフリー・ヒント、オリオール・ヴィニヤルズ、ジェフリー・ディーン「蒸留 ニューラルネットワークの知識. NIPS ディープラーニングでは 表現学習ワークショップ. 2015年1月

[16] 侯晋雷、張英英、鍾喬勇、迪謝、浦志良、周宏. 分割して組み立てる: 学習する ブロック単位のメモリを用いた教師なし異常検出。 IEEE/CVF 国際会議議事録 コンピュータビジョン (ICCV) . 8791~8800ページ、2021年10月。 1.2.6.8

[17] フー・ウェンペン、ワン・メンユー、チン・チー、マー・ジンウェン、ピン Liu. Hm: 1クラス学習への総合的アプローチ。 H・ラロシェル、M・ランザト、R・ハドセル、MFバルカン、 H. Lin 編集『Advances in Neural Information Processing Systems』第33 巻、19111~19124ページ。Curran Associates, Inc., 2020年. 8

[18] Diederik P KingmaとJimmy Ba. Adam: A method for 確率的最適化. arXiv プレプリント arXiv:1412.6980、 2014年6月

[19] ディーデリク・P・キングマとマックス・ウェリング. 自動エンコーディングの可 変ベ. 2013. 2

[20] アレックス・クリジェフスキー. 多層的な特徴の学習 小さな画像. 2009年7月

[21] アレックス・クリジェフスキー、イリヤ・スツケヴァー、ジェフリー・E・ヒント 深層畳み込みニューラルネットワークを用いたImageNet分類. 第25回国際神 経情報処理システム会議論文集 - 第1巻、 NIPS'12, 1097~1105ページ、レッドフック、ニューヨーク州、米国、2012年. Cur-ran Associates Inc. 4

[22] ヤン・ルカン「手書き数字のmnistデータベース」 1998年7月

[23] リー・チュンリャン、ソン・キヒョク、ユン・ジンソン、トーマス Pfister. Cutpaste: 異常検知と位置特定のための自己教師学習. IEEE/CVF Proceedings コンピュータビジョンとパターン認識に関する会議 (CVPR) . 9664~9674ページ、2021年6月. 1.3.4.6.7

[24] W. Liu, D. Lian W. Luo, S. Gao. 異常検知のための未来フレーム予測 - 新たなベ ースライン. 2018年 IEEE コンピュータビジョンとパターン認識会議 (CVPR) . 2018年1月

[25] パオロ・ナポレターノ、フラビオ・ピッコリ、ライモンド・スケッティニ。 CNNベースのナノファイバー材料における異常検出 自己相似性. センサー, 18(1), 2018. 3

[26] Hyunjong Park, Jongyoun Noh, Bumsu Ham. 異常検知のための記憶誘導 型正常性学習。 IEEE/CVF コンピュータビジョンとパターンに関する会議 認識 (CVPR) . 2020年6月. 1.2.3

[27] Pramuditha Perera, Ramesh Nallapati, Bing Xiang, Oc-gan : 制約付き GANS を用いた1クラス新規性検出

潜在表現。IEEE/CVFコンピュータビジョンとパターン認識会議の議事録、ページ 2898–2906, 2019年7, 8

[28] マスード・ブーレザ、バハラム・モハマディ、モスタファ・カーキ、サミール・ブアンドゥール、ヒケム・スヌーシ、モハメド Sabokrou. G2d: 異常検出のための生成。IEEE/CVF Winter Conference on Applications of コンピュータビジョン、2003〜2012ページ、2021年、2.8

[29] タル・ライス、ニヴ・コーエン、リロン・バークマン、イエディド・ホシェン。 Panda: 異常検出のための事前学習済み特徴の適応 セグメンテーション。IEEE/CVFコンピュータビジョンとパターン認識会議 (CVPR)の議事録では、 2021年6月、2806〜2814ページ、3.4.6

[30] オリバー・リップベル、パトリック・メルテンス、ドリット・メルホフ「異常検出のための事前学習済み深層特徴における正常データの分布モデル化」2020年第25回 国際パターン認識会議 (ICPR)、6726-6733ページ 2021年3月

[31] ルーカス・ラフ、ロバート・ヴァンダーミューレン、ニコゲルニッツ、ルーカス Deecke, Shoaib Ahmed Siddiqui, Alexander Binder, Em-manuel Muller, Marius Kloft. 「深層1クラス分類」。Jennifer DyとAndreas Krause編、第35回国際機械学会論文集。 機械学習論文集第80巻「学習」 研究、4393〜4402ページ。PMLR、2018年7月10〜15日。2

[32] モハメドレーザ・サレヒ、ホセイ・ミルザイ、ダン・ヘンドリックス、 イーシュアン・リー、モハメド・ホセイ・ローバン、モハメド サボクロウ。異常性、新規性、オープンセットに関する統一的な調査、 および分布外検出：ソリューションと将来の課題 lenges. arXivプレプリント arXiv:2110.14051, 2021. 7

[33] モハメドレーザ・サレヒ、ニウシャ・サジャディ、ソローシュ Baselizadeh, Mohammad H. Rohban, Hamid R. ラビー。異常に関する多重解像度知識蒸留 検出。IEEE/CVF会議論文集 コンピュータビジョンとパターン認識 (CVPR)、ページ 14902–14912、2021年6月。1.2.3.6.7.8

[34] トーマス・シュレーグル、フィリップ・ゼーボック、セバステアン・M・ヴァルトスタイン、ゲオルグ・ラングス、ウルスラ・シュミット＝エアフルト。f.アノガン: 速い 生成的敵対的学習による教師なし異常検出 ネットワーク。医用画像解析, 54:30–44, 2019. 1, 2

[35] ベルンハルト・ショルコブフ、ジョン・C・ブラット、ジョン・ショウ・テイラー、アレック ス・J・スモラ、ロバート・C・ウィリアムソン。高次元分布の支持度の推定。ニューラルコンピューティング、 13(7):1443–1471, 2001年2月

[36] David MJ TaxとRobert PW Duin. サポートベクターデータ 説明。機械学習, 54(1):45–66, 2004.2

[37] Frederick TungとGreg Mori. 類似性保存知識蒸留。IEEE/CVF国際コンピュー タビジョン会議 (ICCV)の議事録、2004年10月 2019年4月

[38] シャンカン・ヴェンカタラムナン、クアン・チュアン・ベン、ラー・ジャット・ヴィクラ ム・シン、アビジット・マハラノビス。注意 画像における異常部位の特定を誘導する。欧州では コンピュータビジョンに関する会議、485〜503ページ、Springer、 2020年1月

[39] 王國東、韓秀民、丁琦瑞、黃迪。 異常検出のための生徒と教師の特徴ピラミッドマッチング、2021年1.3

[40] ジー・チャン・ウー、ディン・ジェ・チェン、チオ・シャン・フー、ティン・ルー・リウ。異常に 対する教師なしメタフォーマーの学習 検出。IEEE/CVF Internationalの論文集に掲載。 コンピュータビジョン会議 (ICCV)、4369〜4378ページ、 2021年10月2日、6日、7日

[41] Han Xiao, Kashif Rasul, Roland Vollgraf. Fashion-mnist: マシンベンチマー クのための新しい画像データセット 学習アルゴリズム、2017年7月

[42] Xudong Yan, Huaidong Zhang, Xuemiao Xu, Xiaowei Hu, Pheng-Ann Heng と。意味的文脈の学習 教師なし異常検出のための正常サンプル。AAAI人工知能会議議事録、 35(4):3110–3118, 2021年5月。1, 2, 3

[43] Jihun YiとSungroh Yoon. Patch svdd: パッチレベルのsvdd 異常検出とセグメンテーション。 アジアコンピュータビジョン会議 (ACCV)、11月 2020年2月6日

[44] セルゲイ・ザゴリコとニコス・コモダキス「広域残余ネットワーク」エドウィン・R・ハンコッ ク、リチャード・C・ウィルソン、ウィリアム・ APスミス編『英国マシンビジョン会議 (BMVC)議事録』、87.1〜87.12ペー ジ。BMVAプレス、 2016年9月4日

[45] ムハンマド・ザイガム・ザヒール、ジン・ハ・リー、マルセラ・アストリッド、 トイ・スニク。古いものは金なり : 敵対的に再定義する 学習済み1クラス分類器の学習パラダイム。IEEE/CVFコンピュータビジョン会 議の議事録に掲載。 パターン認識、14183–14193ページ、2020年2.8

[46] ビチャン・ザフルタニク、マティ・クリスタン、ダニエル・スコカジ。視覚的な異常を検 出するための修復による再構築。パターン 認識、112:107706、2021年。1.2.3.6.7

[47] マシュー・D・ザイラー、ディリッパ・クリシュナン、グラハム・W・テイラー、 ロブ・ファークガス。デコンボリューションネットワーク。2010年IEEEコンピュー タソサエティコンピュータビジョンとパターンに関する会議 認識、2528–2535ページ、2010年。4

[48] Kang Zhou, Yuting Xiao, Jianlong Yang, Jun Cheng, Wen Liu, Weixin Luo, Zaiwan Gu, Jiang Liu, Shenghua Gao. p-netを用いた構造-テキスト関係の符号化 網膜画像における異常検出。コンピュータビジョンでは、 ECCV 2020: 第16回ヨーロッパ会議、英国グラスゴー、2020年8月23〜28日、議 事録、パートXX 16.360〜377ページ。 シュプリングー、2020年1月

[49] ジュー・ジンゴオ、タン・シーシャン、チェン・ダーペン、ユウ・シージエ、ヤクン Liu, Mingzhe Rong, Aijun Yang, Xiaohua Wang. 相補関係の対照蒸留。 Proceedingsに掲載 IEEE/CVFコンピュータビジョンとパターン認識会議 (CVPR)の論文、9260〜 9269ページ、2021年6月。4

[50] デヴィッド・ジマラー、イェンス・ピーターセン、グレゴール・コーラー、ポール・ジェイガー、ピー ター・フル、トビアス・ロス、ティム・アドラー、アニカ・ラインケ、レナ マイヤー＝ハイン、クラウド・マイヤー＝ハイン。メディカル・アウトオブ・ディストリビュー ション・アナリシス・チャレンジ2021。2021年3月。1